

Поступариум

Поступариум

Умный чат-бот, который отвечает на вопросы абитуриентов ФКН НИУ ВШЭ о поступлении, программах, баллах и олимпиадах



В пиковые периоды учебный офис не справляется с потоком вопросов

700+

вопросов в одном **Telegram-чате** за приёмную кампанию*

24/7

режим работы нужен **абитуриентам** — офис работает только в будни

80%

вопросов — **типовые и повторяющиеся**, ответы на них разбросаны по регламентам

Почему просто **подключить LLM** — недостаточно

01

Галлюцинации

LLM уверенно придумывает **несуществующие проходные баллы**, олимпиады и сроки. Цена ошибки — поступление абитуриента.

02

Устаревшие знания

Модель ничего не знает про правила приёма **текущего года** — её обучали на данных прошлых лет.

03

Дорогие запросы к модели

Отправлять все регламенты в контекст на каждый вопрос — **сотни тысяч токенов** и неподъёмный счёт от API.

04

Нет ссылок на источник

Чистая LLM не покажет, **откуда взят ответ**. Абитуриент не сможет проверить — и не поверит боту.

Умный Telegram-бот, отвечает 24/7 за несколько секунд

01 Ответы за несколько секунд

Абитуриент задаёт вопрос — и **получает ответ сразу**, в любое время суток, без очередей и ожидания.

02 Только из официальных регламентов

Под капотом — **RAG поверх документов ФКН**. Модель отвечает не из воздуха, а из актуальных правил приёма.

03 Привязка к регламенту


Каждый ответ внутренне связан с **конкретным пунктом документа** — администратор и разработчик видят источник и могут проверить корректность.

04 Самообучается на фидбеке

Лайки и дизлайки от пользователей **чищают кеш** и улучшают качество ответов день ото дня.

Как это **работает**

- 1 Абитуриент пишет вопрос **обычным языком** — прямо в Telegram
- 2 Бот **уточняет**, если что-то непонятно
- 3 Отвечает **строго из регламентов ВШЭ** и честно предупреждает о рисках
- 4 Просит **оценить ответ**



Три уровня **умного поиска**

01

Преодоление сленга

Студенческий сленг («пми», «всерос») автоматически переводится на официальный язык документов через регулярные выражения.

02

Умная декомпозиция

Если вопрос составной, **YandexGPT разбивает его** на несколько подзапросов — и собирает полный ответ из всех частей.

03

Двухэтапное ранжирование

ChromaDB быстро находит кандидатов, затем **Cross-Encoder перепроверяет** релевантность. В модель уходит только самое точное.

Обработка неопределенности и валидация на основе фидбека

01

Уточнение контекста

На размытый вопрос — например, «какие проходные баллы?» без указания программы — бот **не галлюцинирует**, а вежливо спрашивает уточнение.

02

Лайки и дизлайки

Дизлайк на ответ из кеша — **мгновенно удаляет его** из кеша, заносит в чёрный список и отправляет администратору на ручную проверку.

FAQ-кеш делает ответы быстрее и дешевле

01

Семантический FAQ-кеш

Если похожий вопрос уже задавали — ответ **отдаётся мгновенно**, без обращения к модели генерации.

02

Семантическое сравнение

«Когда дедлайн» и «до какого числа подавать документы» — **один и тот же вопрос** для системы.

03

Стоимость стремится к нулю

Чем больше повторов — тем больше попаданий в кеш и **меньше платных запросов** к LLM в пик сезона.

Выбор моделей **поиска**

Изолируем вклад каждого компонента — замер на **50 вопросах** о поступлении, в режиме чистого retrieval.

Модель эмбедингов

Модель	Hit Rate@3	MRR@3
paraphrase-multilingual-MiniLM-L12-v2 118M	0,660	0,583
BAAI/bge-m3 570M	0,740	0,671
intfloat/multilingual-e5-base 278M	0,820	0,748

Переранжирование

Конфигурация	Hit Rate@3	MRR@3
Без переранжирования	0,820	0,748
+ cross-encoder/mmarco-mMiniLMv2-L12-H384-v1	0,860	0,801


Сравнение конфигураций:

накопительное добавление компонентов

Каждая строка добавляет один компонент поверх предыдущей. Замер на **n = 245** вопросах.

Конфигурация	Hit@1	Hit@3	Hit@5	MRR@5	P@3	CR	Lat mean, мс	Lat p95, мс
Base RAG	0,714	0,849	0,906	0,789	0,446	0,667	16	17
+ Reranker	0,796	0,931	0,959	0,862	0,533	0,706	234	408
+ Regex Rewrite	0,820	0,922	0,955	0,872	0,550	0,701	248	462
+ LLM Decomp.	0,784	0,927	0,939	0,852	0,543	0,700	1250	1707
+ FAQ Cache	—	—	—	—	—	0,809	786	1580
+ Agentic Loop	0,820	0,943	0,967	0,882	0,546	0,713	3269	6969

Архитектура решения: RAG-конвейер



Итоги тестирования MVP: метрики качества и безопасности

HIT@5 · ТОЧНОСТЬ ПОИСКА

94,9%

случаев — нужный регламент
гарантированно извлекается и уходит
в модель.

MRR@5

0,87

нужный документ почти всегда
на **первой-второй позиции** выдачи.

ROUGE-L · ПОЛНОТА ОТВЕТА

0,42

совпадение сгенерированного ответа
с **эталонным** из регламента.

ВРЕМЯ ОТВЕТА · P95

17,2с

время от вопроса до ответа в
95% случаев

ФИЛЬТР КОНТЕНТА

97%

отсечения мата, спама и **prompt-
инъекций** — бот не напишет код или
ответит грубо.

RATE LIMITER

12/мин

лимит запросов на пользователя —
защита от **DDoS** и **спам-атак**.

● Live Dashboard — Бот ФКН НИУ ВШЭ

Ключевые метрики

Всего запросов

136

Сегодня

20

За последний час

1

Cache hit % [?]

3%

👍 Рейтинг [?]

82%

Avg latency

5197 мс

👍 🟡 📧 19:01:56 [rag] Какие баллы нужно набрать, чтобы подавать заявление на платное обучение?

🕒 7488 мс

Вопрос пользователя:

Какие баллы нужно набрать, чтобы подавать заявление на платное обучение?

📧 Бот запросил уточнение:

По какой программе ФКН вас интересуют минимальные баллы? (ПМИ, ПАД, КНАД, ЭАД, Программная инженерия, Разработка игр, Робототехника, ДРИП)

↳ Ответ пользователя на уточнение:

ПАД

Ниже — финальный ответ бота на исходный вопрос с учётом уточнения.

Декомпозиция запроса (RAG):

1. минимальные баллы ЕГЭ программное обеспечение автоматизированных систем и данных ПАД
2. проходные баллы на платное обучение ПАД

Ответ бота:

Для подачи заявления на платное обучение по программе «Прикладной анализ данных» (ПАД) необходимо набрать следующие минимальные баллы ЕГЭ:

- Математика: **70 баллов.**
- Информатика и ИКТ / Физика: **60 баллов.**
- Русский язык: **60 баллов.**

👍 Пользователь подтвердил ответ

Маршрут: rag · Источник: rag · Язык: ru · Latency: 7488 мс

СКОЛЬКО СТОИТ **ОДИН ОТВЕТ БОТА**

Расчёт на базе **YandexGPT Lite** — основная LLM проекта

ТЕКСТОВЫЙ ЗАПРОС

~0,5 ₽

средняя стоимость генерации ответа на **текстовый вопрос** — включает извлечение из базы и вызов модели.

ГОЛОСОВОЙ ЗАПРОС

~0,7 ₽

стоимость ответа на **голосовое сообщение** — дополнительно подключается распознавание речи.

Что **дальше**: масштабирование

01

Все факультеты ВШЭ

Перенос отработанной **RAG-архитектуры** на все факультеты НИУ ВШЭ — просто подключаем новые базы знаний: МИЭМ, ФЭН и другие.

02

Студенческий трек

Расширение функционала для **текущих студентов** и интеграция базы сложных внутренних документов — включая ПОПАТКУС.

03

Другие университеты

Внедрение Поступариума **за пределами ВШЭ** — решение легко адаптируется под регламенты любого вуза.



• АВТОР ПРОЕКТА

Веляев Алексей Владимирович

Студент НИУ ВШЭ, направление «Прикладная математика и информатика» (ПМИ)

Научный руководитель: **Андреева Дарья
Александровна**



ПРОТЕСТИРОВАТЬ СЕЙЧАС

Отсканируй QR-код

и запусти бота в Telegram прямо с этого слайда

HIT@5

94,9%

точность поиска

MRR@5

0,87

ранжирование

ОКН

ROUGE-L

0,42

полнота ответа

ВРЕМЯ · P95

17,2^c

время ответа

ФИЛЬТР

97%

мат, спам, инъекции

RATE LIMIT

12/мин

защита от DDoS



СТОИМОСТЬ

~0,5₹

за один ответ

YandexGPT
Lite

основная LLM проекта

ОТВЕТЫ 24/7

RAG

из регламентов ВШЭ



ПРОТЕСТИРОВАТЬ

Запусти бота в Telegram

отсканируй QR — и задай свой вопрос